

Projet — Analyse des données d'une plateforme e-commerce

Contexte

Vous travaillez au sein de l'équipe Data d'une plateforme e-commerce.

L'entreprise souhaite mieux comprendre son activité commerciale afin de répondre à plusieurs questions :

- Quels sont les produits les plus vendus ?
- Quelles catégories génèrent le plus de chiffre d'affaires ?
- Quels clients sont les plus actifs ?
- Comment évoluent les ventes dans le temps ?
- Existe-t-il des anomalies dans les données ?
- Quels indicateurs peuvent aider l'entreprise à mieux comprendre son activité ?

Votre mission consiste à construire la base de données nécessaire, charger les données fournies puis réaliser une analyse complète en SQL.

Partie 1 — Modélisation de la base

À partir des règles métier ci-dessous, vous devez déterminer les tables nécessaires à la base de données.

Vous devez créer vous-mêmes le fichier :

`create_schema.sql`

Règles métier

Clients

La plateforme possède des clients.

Pour chaque client, on souhaite conserver :

- son nom ;
- son prénom ;
- son adresse email ;
- sa ville ;

- sa date d'inscription.

Un client peut passer plusieurs commandes.

Un client peut également être inscrit, mais ne jamais avoir passé de commande.

Produits

La plateforme vend différents produits.

Pour chaque produit, on souhaite conserver :

- son nom ;
- sa catégorie ;
- son prix actuel ;
- son stock disponible.

Un produit peut ne jamais avoir été vendu.

Un produit peut apparaître dans plusieurs commandes.

Commandes

Un client peut passer plusieurs commandes.

Pour chaque commande, on souhaite conserver :

- le client ayant passé la commande ;
- la date de la commande ;
- le statut de la commande.

Les statuts possibles sont :

- payée
- expédiée
- livrée
- annulée

Une commande contient une ou plusieurs lignes de commande.

Lignes de commande

Une ligne de commande représente un produit acheté dans une commande.

Pour chaque ligne, on souhaite conserver :

- la commande concernée ;
- le produit concerné ;
- la quantité commandée ;
- le prix unitaire effectivement payé.

Attention :

Le prix payé lors d'une commande peut être différent du prix actuel du produit.

Cela permet notamment de représenter des promotions ou des réductions historiques.

Travail demandé

À partir de ces règles, créez les tables nécessaires.

Votre base doit notamment respecter les relations entre les différentes entités.

Vous devez réfléchir à :

- la clé primaire de chaque table ;
- les clés étrangères ;
- les types de données ;
- les champs obligatoires ;
- les contraintes pertinentes ;
- les relations entre les tables.

Vous devez être capables de justifier vos choix.

Partie 2 — Chargement des données

Le fichier `seed_ecommerce.sql` vous est fourni.

Ce fichier contient les données de la plateforme.

Vous devez :

1. créer votre base ;
2. exécuter votre fichier `create_schema.sql` ;
3. exécuter le fichier `seed_ecommerce.sql` ;
4. vérifier que les données ont correctement été importées.

Vous devez notamment vérifier :

- le nombre de clients ;
 - le nombre de produits ;
 - le nombre de commandes ;
 - le nombre de lignes de commande.
-

Partie 3 — Analyse SQL

Créez un fichier :

`analysis.sql`

Toutes vos requêtes SQL doivent être regroupées dans ce fichier.

Règle de calcul : le montant d'une ligne correspond à la quantité multipliée par le prix effectivement payé. Les commandes au statut « annulée » ne doivent pas être prises en compte dans le chiffre d'affaires, les quantités vendues et le panier moyen.

Exercice 1 — Explorer les produits

Afficher la liste des produits avec :

- leur nom ;
- leur catégorie ;
- leur prix ;
- leur stock.

Puis identifiez les produits dont le prix est supérieur à 100 €.

Exercice 2 — Explorer les clients

Afficher les clients habitant dans une ville donnée.

Puis déterminer combien de clients sont enregistrés dans chaque ville.

Exercice 3 — Explorer les commandes

Afficher les commandes avec :

- leur identifiant ;
 - leur date ;
 - leur statut ;
 - les informations du client associé.
-

Exercice 4 — Calculer le montant d'une ligne

Pour chaque ligne de commande, calculer le montant correspondant à la ligne.

Le montant doit prendre en compte :

- la quantité ;
 - le prix effectivement payé.
-

Exercice 5 — Calculer le montant des commandes

Calculer le montant total de chaque commande.

Vous devez obtenir un résultat contenant au minimum :

- l'identifiant de la commande ;
 - sa date ;
 - son statut ;
 - son montant total.
-

Exercice 6 — Chiffre d'affaires par catégorie

Calculer le chiffre d'affaires généré par chaque catégorie de produits.

Présenter les catégories avec :

- leur chiffre d'affaires ;
 - la quantité totale de produits vendus.
-

Exercice 7 — Produits les plus vendus

Identifier les produits ayant généré les plus grandes quantités vendues.

Présenter au minimum :

- le produit ;
- la catégorie ;
- la quantité totale vendue.

Présenter les 10 premiers résultats.

Exercice 8 — Produits générant le plus de chiffre d'affaires

Identifier les produits ayant généré le plus de chiffre d'affaires.

Présenter :

- le produit ;
 - la catégorie ;
 - le chiffre d'affaires.
-

Exercice 9 — Clients

Calculer pour chaque client :

- le nombre de commandes ;
- le montant total dépensé.

Vous devez également identifier les clients n'ayant jamais passé de commande.

Exercice 10 — Panier moyen

Calculer le panier moyen de la plateforme.

Puis calculer le panier moyen par mois.

Vous devez être capable d'expliquer la différence entre :

- chiffre d'affaires ;
 - nombre de commandes ;
 - panier moyen.
-

Partie 4 — Transformation des données

Vous devez maintenant enrichir les résultats précédents avec des informations calculées.

Exercice 11 — Catégoriser les commandes

Créer une analyse permettant de classer les commandes selon leur montant.

Utiliser les catégories suivantes :

- Petit panier : moins de 500 €
- Panier moyen : de 500 € à moins de 1 500 €
- Gros panier : 1 500 € ou plus

Votre résultat doit permettre d'identifier la catégorie de chaque commande.

Exercice 12 — Analyse temporelle

Analyser l'évolution du chiffre d'affaires au cours de l'année.

Produire un résultat permettant de comparer les ventes selon les périodes.

Vous devez identifier :

- les périodes les plus importantes ;
 - les périodes les moins importantes ;
 - l'évolution générale de l'activité.
-

Partie 5 — Qualité des données

La qualité des données est également une problématique importante pour l'entreprise.

Exercice 13 — Détecter une incohérence

Rechercher les commandes dont la date est antérieure à la date d'inscription du client.

Pour chaque anomalie, afficher au minimum :

- l'identifiant de la commande ;
- l'identifiant du client ;
- la date de commande ;

- la date d'inscription.

Vous devez également indiquer combien d'anomalies ont été détectées.

Exercice 14 — Produits sans vente

Identifier les produits qui n'ont jamais été vendus.

Pour chacun d'eux, afficher :

- le produit ;
- sa catégorie ;
- son prix ;
- son stock.

Puis expliquer pourquoi cette information peut être intéressante pour l'entreprise.

Partie 6 — Tableau de bord en SQL

Vous devez maintenant construire les indicateurs clés de l'activité, toujours en SQL et dans le fichier `analysis.sql`.

Exercice 15 — Indicateurs clés

A. Exploration

Présenter :

- le nombre de lignes de chaque table ;
- les colonnes et leurs types de données (indice : `information_schema.columns`) ;
- les éventuelles valeurs manquantes.

B. Analyse commerciale

Calculer, si possible en une seule requête :

- le chiffre d'affaires total ;
- le nombre de commandes ;
- le panier moyen ;

- le nombre de clients actifs.

Calculer ensuite le taux d'annulation des commandes.

C. Analyse des clients

Identifier les clients ayant généré le plus de chiffre d'affaires.

Présenter au minimum les 10 premiers.

D. Synthèse mensuelle

Créer une table `synthese_mensuelle` (`CREATE TABLE ... AS SELECT`) contenant, pour chaque mois :

- le nombre de commandes ;
- le chiffre d'affaires ;
- le panier moyen.

Expliquer ce que cette table permet d'observer sur l'évolution de l'activité.

Partie 7 — Analyse libre

Cette dernière partie est volontairement ouverte.

La direction vous demande :

« À partir des données disponibles, trouvez des informations qui pourraient nous aider à mieux comprendre notre activité commerciale. »

Vous devez identifier **au minimum trois analyses supplémentaires** qui n'ont pas été demandées précédemment.

Pour chaque analyse :

1. formuler une question ;
2. identifier les données nécessaires ;
3. réaliser l'analyse ;
4. présenter le résultat ;
5. expliquer ce que vous observez ;
6. expliquer pourquoi cette information peut être intéressante pour l'entreprise.

Toutes les analyses doivent être réalisées en SQL.

Livrables et travail collaboratif

Le projet doit être réalisé **en groupe à l'aide de Git et GitHub**.

Chaque groupe doit créer un dépôt GitHub dédié au projet et utiliser Git pour organiser et suivre son travail.

Structure attendue du dépôt

```
projet-ecommerce/  
|  
├── create_schema.sql  
├── seed_ecommerce.sql  
├── analysis.sql  
├── README.md  
└── .gitignore
```

Le fichier **README.md** doit expliquer :

- comment créer la base ;
- comment créer les tables ;
- comment charger les données ;
- comment exécuter les analyses.

Le README doit également présenter brièvement les principales conclusions de votre analyse.

Évaluation

Partie	Points
Modélisation et création des tables	4
Requêtes SQL	5

Transformation et analyse SQL	3
Qualité des données	2
Tableau de bord SQL	3
Analyse libre et interprétation	2
Qualité du projet / README	1
Total	20

L'objectif n'est pas uniquement d'obtenir le bon résultat.

Vous devez être capables de **comprendre les données, choisir une méthode adaptée, justifier vos choix et interpréter les résultats obtenus.**